学习相邻关系，编码时遵循已学顺序

训练决定规则；编码只读取规则。频次、rank 和 token ID 各有自己的含义。

1 从带频次的语料学习

词频	基础符号（含词末标记）
× 5	c a t </w>
× 2	c a t s </w>
× 3	c a p </w>
× 1	c a p s </w>

c + a　5 + 2 + 3 + 1 = 11

首轮胜出；后续每轮重新计数。

2 冻结合并规则

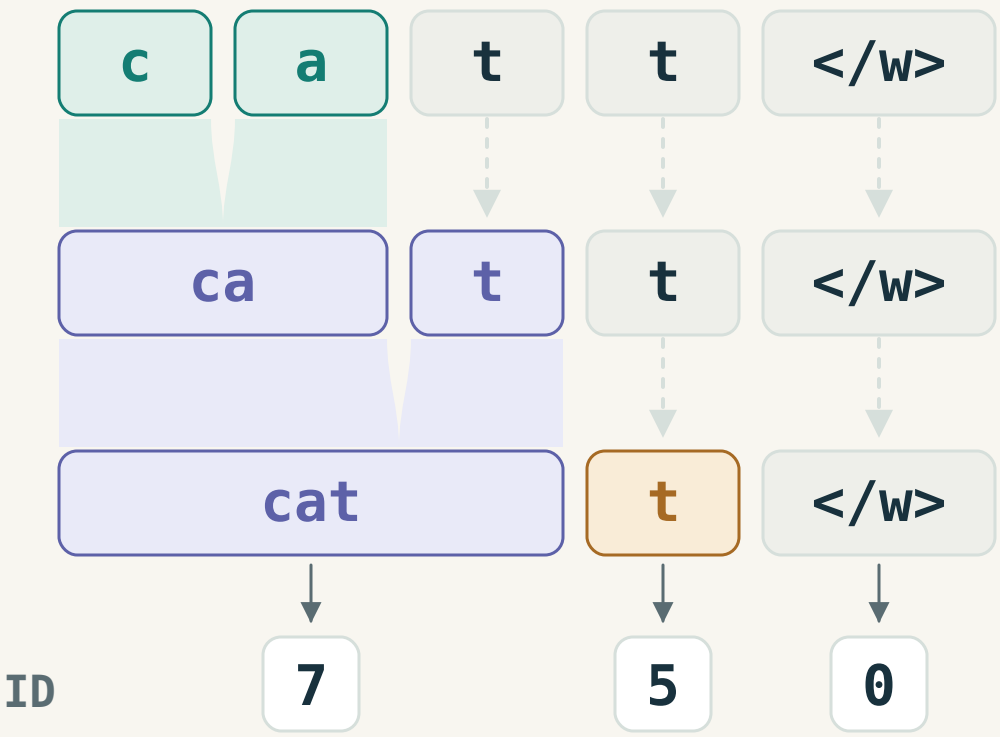
rank	固定规则	n
0	c + a → ca	11
1	ca + t → cat	7
2	cat + </w> → cat</w>	5
3	ca + p → cap	4
4	cap + </w> → cap</w>	3

n = 这条规则被选中时的计数

训练结束 · 规则固定

3 编码训练时没有见过的 catt

只匹配当前相邻的 pair；保持各个 token 的位置跨度。



rank 0　c + a → ca

合并后，再检查相邻关系。

rank 1　ca + t → cat

不重新计数，不扩充词表。

停止　**没有可用的相邻规则**

cat 后面的第二个 t 阻止 rank 2。

cat 与 </w> 仍不相邻。

输出 ID = [7, 5, 0]。ID ≠ rank；本例 ID 0 是词末标记，不是 EOS。